

Aplicación de algoritmos de aprendizaje automático a sistemas robóticos multiagente para la programación y control de operaciones productivas y logísticas: una revisión de la literatura reciente

Rommel Velastegui, Raúl Poler, Manuel Díaz-Madroño

Recibido: 31 de Marzo de 2022
Aceptado: 27 de Noviembre de 2022

<https://doi.org/10.37610/dyo.v0i80.643>

Resumen

Este artículo presenta una revisión bibliográfica de los algoritmos de aprendizaje automático utilizados para dar solución a la problemática de los MARS para la PCP productivas y logísticas. Se ha analizado y clasificado la información en base al criterio aplicación en las industrias donde los resultados más relevantes fueron con un 60% experimental, 13% celdas de producción, 7% simulación, 7% teórico y otro 13% que no se especifica. Se ha encontrado, además, varios algoritmos de aprendizaje IA, DL, DRL, QL, que se pueden aplicar en las industrias. El objetivo es construir un documento que sirva de punto de partida para investigadores y profesionales en el ámbito de algoritmos de aprendizaje automático en sectores industriales.

Palabras clave

Sistemas robóticos multiagente (MARS), programación y control de operaciones (PCP), producción y logística, algoritmos de aprendizaje.

1. Introducción

El presente documento muestra una revisión bibliográfica de los artículos científicos publicados a partir del año 2014 sobre el uso y aplicación de algoritmos de aprendizaje enfocado a los MARS y cómo actúan en la programación y control de operaciones productivas y logísticas.

El objetivo del artículo es determinar el estado actual de la investigación sobre MARS y, posteriormente, proponer líneas futuras para la investigación y desarrollo de algoritmos en el área de estudio. Como medio para el desarrollo del documento se han propuesto las siguientes preguntas de investigación:

- PI1: ¿Cuál es el estado actual de las investigaciones sobre la problemática de MARS para la programación y control de operaciones productivas y logísticas?
- PI2: ¿Qué documentos científicos han aportado algún tipo de soluciones a la problemática de MARS para la programación y control de operaciones productivas y logísticas?
- PI3: ¿Cómo se pueden caracterizar los algoritmos usados en la solución al problema de MARS para la programación y control de operaciones productivas y logísticas?
- PI4: ¿Que líneas de investigación se pueden plantear en base al estado actual de las investigaciones sobre los MARS para la programación y control de operaciones productivas y logísticas?



Rommel Velastegui (1,2)
rvelast@doctor.upv.es

ORCID: 0000-0001-6653-7933

Raúl Poler (1)
rlarroyo@comillas.edu

ORCID: 0000-0003-4475-6371

Manuel Díaz-Madroño (1)
mlarroyo@comillas.edu

ORCID: 0000-0003-1693-2876

(1) Universitat Politècnica de València, Research Centre on Production Management and Engineering (CIGIP), Alcoy, Alicante, Spain

(2) Faculty of Systems, Electronics and Industrial Engineering, Universidad Técnica de Ambato, De los Chasquis Av., Ambato, 180103, Ecuador

La estructura del artículo contiene siete secciones descritas a continuación: la sección 1, indica una breve descripción de lo que se quiere conseguir con la investigación; la sección 2, representa la metodología de revisión bibliográfica aplicada; la sección 3, describe el problema de la investigación; la sección 4, caracteriza los algoritmos de aprendizaje a partir de la literatura como propuesta de solución a los MARS en la programación y control de operaciones productivas y logísticas; la sección 5, especifica el tipo de algoritmos para solucionar problemas de los MARS; la sección 6, responde las preguntas de investigación, analiza los principales hallazgos y propone las futuras líneas de investigación; y finalmente, la sección 7, propone las conclusiones.

2. Metodología

La revisión de la literatura científica es primordial en una investigación, por lo que el objetivo de este estudio es: analizar minuciosamente las investigaciones actualmente realizadas sobre MARS para la programación y control de operaciones productivas y logísticas, identificando los aspectos más relevantes, así como los métodos estudiados hasta la actualidad. En este apartado se da respuesta a la PI1.

Para el desarrollo de la revisión se ha seguido la metodología propuesta por (Sekala et al., 2018), la cual consta de los siguientes pasos .

El primer paso consiste en la selección de documentos científicos de la base de datos Scopus, utilizando los siguientes criterios de búsqueda:

(TITLE-ABS-KEY (("robotic system*")) AND TITLE-ABS-KEY ((production) OR (logistic*)) AND TITLE-ABS-KEY ((agent*) OR ("multi agent") OR ("multi*agent")))*

Con esta búsqueda se obtienen 49 artículos científicos. Sin embargo, en una segunda búsqueda se le incrementa el criterio de “Manufacturing”, por lo que plantean los siguientes criterios de búsqueda:

(TITLE-ABS-KEY ("robotic system*") AND TITLE-ABS-KEY ("product*" OR "manufactur*" OR "logistic*") AND TITLE-ABS-KEY ("multi* agent*"))*

Dando como resultado 54 documentos científicos que constan en las siguientes especificaciones detallados en la Tabla 1.

Tabla 1 Criterios de búsqueda

Identificación	Descripción
Base de datos	SCOPUS
Lenguaje	Inglés
Áreas científicas	Todas
Revistas	Todas
Tipos de documento	Documento de sesión Artículo Revisión de la conferencia Capítulo del libro Revisar
Campo de búsqueda	Todas
Fecha de búsqueda	Enero 2022
Año inicial de búsqueda	1994

En el segundo paso, se han excluido las investigaciones a través del análisis y revisión de los títulos y resúmenes, logrando descartar 39 documentos, debido que no se adaptan al campo de aplicación en el sector industrial, logrando obtener 15 documentos científicos de interés.


Para el tercer paso se agruparon los documentos según el enfoque del algoritmo de aprendizaje de MARS y PCP.

En el cuarto paso se toman los hallazgos significativos para la investigación. Entre ellos se buscan las propuestas de solución con la revisión de las conclusiones.

Finalmente, el paso cinco plantea los principales hallazgos y futuras líneas de investigación con la revisión de las recomendaciones o discusiones.

En la Figura 1 se propone una síntesis de la metodología propuesta en la investigación con los hallazgos de cada paso.

Figura 1 Metodología de búsqueda



3. Planteamiento del problema

Los MARS se definen como el conjunto de diferentes agentes inteligentes que tienen cierto nivel de autonomía que cooperan entre sí para alcanzar un objetivo común (Stefanova-Stoyanova & Stankov, 2020). Sin embargo el problema del DRL en los MARS dentro de la PCP es la presencia de diferentes agentes inteligentes que deben cumplir varias restricciones en un entorno cambiante para cumplir un objetivo común (Sagar et al., 2018).

El propósito de los MARS es trabajar cooperativamente en la mayoría de procesos de programación y control de operaciones productivas y logísticas (Deeks, 2022). El desarrollo de este trabajo colaborativo puede ocasionar errores o cruce de información en los enjambres de robots, lo que podría ocasionar pérdida de tiempo, dinero y recurso humano (Lujak et al., 2021).

Cuando se pretende crear un algoritmo de aprendizaje para los MARS, las dificultades pueden darse por varias condiciones: (a) diferentes agentes inteligentes, (b) entorno de trabajo dinámico, (c) especificaciones de los pedidos por la exigencia de los clientes; y (d) sistemas de producción autorregulables por variables específicas como los tiempos de producción, período de demanda y pedidos anticipados (Nilles et al., 2019).

Las industrias buscan que se implementen sistemas de producción autorregulables, para que la nueva programación

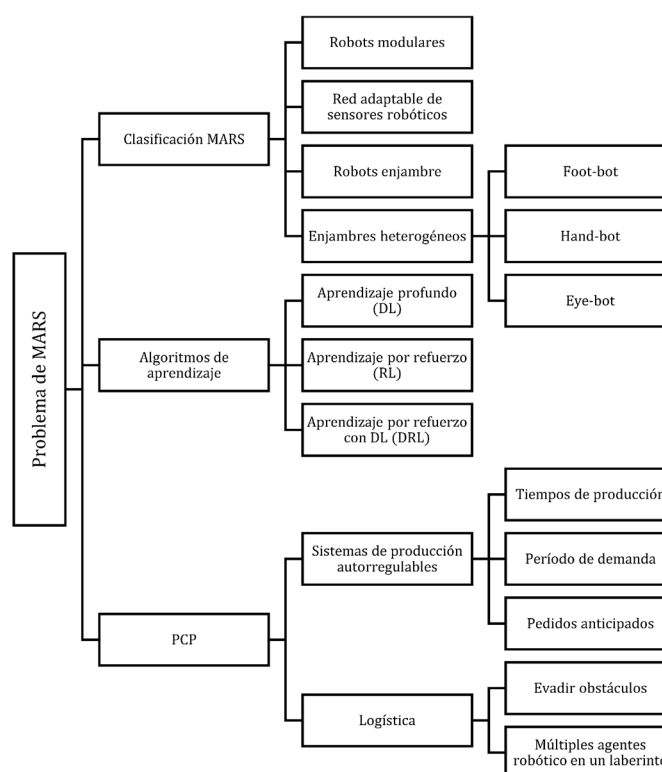
propuesta se logre en el menor tiempo posible (Webster et al., 2014).

Las condiciones complejas de PCP exigen que se manejen variables complejas para los MARS, por lo que surge la necesidad de la aplicación de entornos virtuales simulados basados en algoritmos de aprendizaje para los diferentes agentes inteligentes que intervienen en las tareas (Demesure et al., 2014). Estas metodologías exactas permiten manejar varios escenarios donde se puedan experimentar, además que proporcionan cierto tipo de flexibilidad para proponer soluciones óptimas (Antzoulatos et al., 2014).

Con la ayuda de los algoritmos de aprendizaje, se busca proponer en las industrias escenarios simulados. En donde intervengan diferentes agentes inteligentes, para buscar soluciones a la problemática identificada. Por lo general las principales limitaciones de implementar en un entorno real son falta de recursos o de capacidad física de las plantas industriales (Serebrenny et al., 2019).

La Figura 2, se muestran aspectos para fundamentar la problemática de DL para MARS, se divide en tres subniveles la clasificación. La primera MARS los cuales indican los tipos de robots existentes, resaltando los enjambres heterogéneos foot – bot, hand – bot, eye – bot. La segunda los algoritmos de aprendizaje, se clasifican en tres DL, RL y DRL y finalmente la tercera PCP, se clasifican en dos para producción autorregulable y logística, que abarca en su mayoría a la problemática de la investigación.

Figura 2 Problema DRL para MARS..



4. Caracterización de los algoritmos de aprendizaje a partir de la literatura como propuesta de solución a MARS en la programación y control de operaciones productivas y logísticas

Para dar solución a la pregunta dos de la investigación (PI2), se plantea la revisión de documentos científicos de las posibles soluciones a los MARS. Se parte desde las temáticas básicas como ML PCP hasta temáticas actuales como IA, DL, DRL, QL y algoritmos de aprendizaje que se pueden aplicar en el funcionamiento de diferentes agentes inteligentes en las industrias (Deeks, 2022).

Los robots bajo el principio del test de Turing, han sido muy útiles en las industrias. Se han utilizado para actividades complejas y repetitivas. Estos sistemas electromecánicos inicialmente fueron controlados por un computador o circuitos eléctricos específicos (Papadopoulos et al., 2021).

Consecutivamente con la aparición de la IA, los robots han mejorado su funcionamiento en entornos cambiantes e impredecibles. Con estos avances se ha logrado cierta autonomía para alcanzar objetivos específicos.

Además, los procesos industriales que van involucrando gran número de MARS que cooperan entre sí, utilizan variedad de tecnologías como DL, DRL, QL y algoritmos de aprendizaje para alcanzar objetivos comunes. A continuación, la Tabla 2 muestra la agrupación de los algoritmos de aprendizaje, ciertas características particulares y finalmente ejemplos aplicados a producción y control industrial de operaciones productivas y logísticas (Zinn et al., 2021).

La evolución industrial, los nuevos estilos de producción y control de empresas: farmacéuticas, alimenticias, automoción, químicas, exigen que las plantas industriales vayan implementando automatización en los sistemas electromecánicos (Lujak et al., 2021).

Tabla 2 Grupos del aprendizaje automático (Zafeiropoulos et al., 2022).

Aprendizaje	Característica	Ejemplos
Supervisado	Algoritmos elaboran predicciones basadas en varios ejemplos, se utiliza cuando se conoce el resultado.	Proyección de pedidos, a partir de historial de datos.
No supervisado	Algoritmo identifica automáticamente organizando datos o estructura, se utiliza cuando no se sabe el resultado	Creación de nuevos productos.
Reforzado	Algoritmos que aprenden de los resultados anteriores y deciden que acción realizar, compara y decide si fue una decisión correcta, incorrecta o neutra, se utiliza en sistemas automatizados que deben tomar decisiones pequeñas sin actuar humanos.	Optimización en líneas de producción.

El impacto de la robótica colaborativa en la industria 4.0, genera algunos beneficios entre ellos tenemos: fabricación homogénea, calidad, producción continua, sin interrupciones, disminuir tiempos de fabricación, reducción de costos de materiales y menor esfuerzo humano (Deeks, 2022).

La Tabla 3, categoriza los algoritmos mayormente utilizados en agentes inteligentes o MARS. Siendo los de clasificación los mayormente utilizados debido que realizan cálculos predictivos para asignar datos a categorías preestablecidas según el agente utilizado (Arques Corrales & Aznar Gregori, 2020).

Adicional, la Tabla 3, explica las categorías, los tipos de algoritmo, la definición y ejemplos que en la revisión bibliográfica se pudo encontrar (Zinn et al., 2021).

La categorización busca encontrar con su diversificación, una solución a las diversas actividades de los agentes múltiples que se encuentran en las industrias (Dürica et al., 2019). Siendo el objetivo principal de los algoritmos de aprendizaje evitar colisiones entre ellos (Zafeiropoulos et al., 2022).

Tabla 3 Categoría de algoritmos de aprendizaje (Zafeiropoulos et al., 2022).

Categoría	Algoritmo	Definición	Ejemplos
De destino	Binaria	Dos categorías	¿Cumplió con las operaciones productivas?
	Multinomial	Tres o más categorías	¿Qué mes se entrega el pedido?
Buscar datos inusuales	De detección de anomalías	Identifican datos que están fuera de los parámetros	¿Qué productos de este lote son defectuosos?
Predicción de valores	De regresión	Predicción de valores en base a datos históricos	¿Cuál es el costo promedio de consumo de gas?
Cambio de valores en un periodo de tiempo	De serie temporal	Muestran el cambio de un valor determinado a lo largo del tiempo (predicciones, tendencias, estacionalidad, ciclicidad)	¿Qué gastos tendré el año que viene?
De similitud	De clúster	Agrupar datos determinando el nivel de similitud	¿Qué productos son de primera, segunda?
Clasificación	De clasificación	Realizan cálculos predictivos para asignar datos a categorías preestablecidas	¿Este mensaje es una notificación real?

En un análisis más profundo, la Tabla 4, muestra la tipología y los usos de los algoritmos de aprendizaje (Zafeiropoulos et al., 2022). Se observa también los tipos y usos de algoritmos que utilizan los MARS, estos algoritmos de una u otra manera se encuentran relacionados entre si (Ross & Ross, 2022).

Dentro de la función de los algoritmos en su investigación Zafeiropoulos et al (2022), propone que la comunicación entre los MARS satisfaga objetivos individuales. Adicional se busca que a través de esta metodología los robots sean capaces de interactuar con los enjambres dentro de una red experimental (Griparić et al., 2017). Esta metodología tiene como finalidad optimizar los tiempos de producción y buscar la mejor ruta de operación, para incrementar la competitividad de las empresas (Đurica et al., 2019).

Según literatura, los algoritmos para los MARS, garantizan la adaptabilidad en varios sistemas, incrementando la capacidad de resolver automáticamente problemas que pudieran generarse (Shereuzhev & Serebrenny, 2020).

Los problemas de los MARS que puedan generarse dentro de las actividades productivas, los algoritmos de aprendizaje permitirán que exista un control. El tiempo finito adaptativo distribuido del control debe ser el menor posible. Sin embargo, hay que indicar según el caso un protocolo de tiempo finito adaptativo distribuido basado en el algoritmo de recursión y las NN, que busca la mejor solución (Li et al., 2022).

Tabla 4 Tipos de algoritmos de aprendizaje (Zafeiropoulos et al., 2022).

Tipos	Usos
Regresión	Lineal Logística
Instancia	k-Nearest Neighbor (kNN) Self-Organizing Map
Árbol de decisión	Árboles de Clasificación y Regresión (CART) Decisión de Árbol condicional Random Forest
Bayesianos	Naive Bayes Gaussian Naive Bayes Multinomial Naive Bayes Bayesian Network
Agrupación	K-Means K-Medians Hierarchical Clustering
Redes neuronales	Compuerta XOR Perceptron Back-Propagation Hopfield Network MLP: Multi Layered Perceptron
Aprendizaje profundo	Convolutional Neural Networks Long Short-Term Memory Neural Network
Reducción de dimensión	Principal Component Analysis (PCA) t-SNE (próximamente artículo)
Otros	Algoritmos de Aprendizaje por Reglas de Asociación Algoritmos de Conjunto Computer Vision Sistemas de Recomendación Aprendizaje por Refuerzo

Los escenarios simulados permiten que existan varias pruebas y extensos experimentos con una implementación de varios agentes robóticos. Las posibles soluciones ofrecen excelentes resultados en términos de robustez y rendimiento, incluso en escenarios naturales desafiantes (Boldrer et al., 2022).


Para especificar las soluciones, se ha considerado la metodología de (Pérez-Cubero & Poler, 2021), donde se realiza una adaptación de la búsqueda. El análisis de los 15 documentos científicos muestra que el tema de investigación propuesto es novedoso, con un campo de investigación poco explorado.

5. Especificaciones de algoritmos para solucionar problemas de los MARS

Las especificaciones de los algoritmos que responderán a la PI3 son: objetivo del algoritmo, problema, algoritmo de solución, método de validación, número de agentes robóticos, tiempo de cálculo, estos detalles se muestran en la Tabla 5.

En los trabajos revisados, se muestran varios algoritmos de solución, resaltando los más utilizados 3 documentos que utilizan MARS, adicional debido a la especificación de los trabajos se muestran los siguientes algoritmos, Sistema plug and produce, algoritmo CASU, QL, MRS, Robot APOTECA Chemo, HDL, MCLSP-BOSI, Modelo HUC-BI, CTV y en 2 trabajos no se especifican.

Figura 3 Metodología de validación de los MARS.



Dentro de las metodologías mayormente utilizadas en la validación se proponen escenarios simulados. Como muestra la Figura 3 la simulación predomina como el principal método de validación con un 60% del total de la documentación analizada, posteriormente están las metodologías experimental y teórica con un 13% cada una, de igual manera se encuentran la Celda de producción – Feitoll Automation con 7% y finalmente un trabajo que no especifica la metodología de validación con el 7%.

6. Respuestas de preguntas de investigación, análisis de principales hallazgos y futuras líneas de investigación

6.1. Respuesta de preguntas de investigación

Dando respuesta a la PI1, se ha utilizado cinco palabras claves que abarca el tema de la investigación: robotic system, production, manufacturing, logistic, multi-agent. Se ha utilizado símbolos “” en las palabras claves que tienen dos palabras, se ha utilizado asterisco (*) al final de las palabras para mejorar la búsqueda, y operadores booleanos AND y OR, mayormente detallado se encuentra en la metodología. Dando como resultado del estado actual de las investigaciones sobre la problemática propuesta, 54 documentos que tienen relación con los MARS para la programación y control de operaciones productivas y logísticas. La temática es novedosa, nueva, poco estudiada por la complejidad de las variables de estudio se focaliza en los últimos años.

Dando respuesta a la PI2, una vez aplicado el criterio de exclusión (estudios aplicados en las industrias), entre los documentos científicos más relevantes que han aportado soluciones a la problemática de MARS para la programación y control de operaciones productivas y logísticas, tenemos que autores como Shereuzhev & Serebrenny (2020) y Kiktev et al. (2021). Estas investigaciones, presentan a la simulación como principal escenarios o medio de solución. Las simulaciones permiten combinar diferentes agentes

inteligentes. A estos escenarios de producción, se suman los diferentes tipos de algoritmos de aprendizaje, resaltando los supervisados, no supervisados y reforzados. A su vez los algoritmos de aprendizaje propuestos se categorizan para generar escenarios automatizados. Sin embargo existen también criterios de otros autores que manifiestan soluciones experimentales, celdas de producción o criterios teóricos.

Dando respuesta a la PI3, el campo de aplicación de los MARS para la programación y control de operaciones productivas y logísticas es amplio, se puede aplicar en industrias: farmacéuticas, alimenticias, automoción, químicas. Dependiendo del tipo de industria y la complejidad de los agentes inteligentes, se ha identificado nueve tipos de algoritmos de aprendizaje resaltando los de redes neuronales, aprendizaje profundo y otros. Además, los algoritmos de solución que se han encontrado son: algoritmo CASU, MAS, Plug and produce, D-MAS, MRSA, LOT, Robot APOTECA Chemo, Modelo HUC-BI, CTV, que son métodos de validación en su mayoría experimentales, pero también existen simulaciones y teóricas, algo interesante que hay que mencionar es que en estos estudios se puede observar la participación de 10 agentes, y 50 – 100 abejas y un reto que todavía está en estudio es el tiempo de cálculo.

Dando respuesta a la PI4, las líneas de investigación que se pueden plantear son general multidisciplinarias, donde se involucren a los MARS para la programación y control de operaciones productivas y logísticas donde se busque disminuir costos para poder replicar en empresas artesanales o microempresas que no disponen de recursos económicos suficientes para implementar estos sistemas tecnológicos.

6.2. Principales hallazgos

Los principales hallazgos encontrados referente a los algoritmos de aprendizaje para los MARS en la revisión bibliográfica, son:

Đurica et al. (2019), Shereuzhev & Serebrenny (2020), Nair et al. (2019) y Sekala et al. (2018), en sus investigaciones

como objetivo del algoritmo de optimización es optimizar la capacidad colaborativa para mejorar la eficiencia de producción, optimizar el tiempo para resolver problemas, aumentar la productividad en las industrias.

Weichhart et al. (2018), Kiktev et al. 2021, Shereuzhev & Serebrenny, 2020, Sekala et al., 2018, Kirks et al., 2019) y Zhu et al. (2019), en sus estudios experimentales manifiestan que los agentes robots cada vez van ganando espacio en las industrias por su libertad de tomar decisiones más precisas, en vista que los escenarios de las industrias son planificados y por más agentes robóticos inteligentes que existan necesitan supervisión humana.

Kiktev et al. (2021), Shereuzhev & Serebrenny (2020), Sekala et al. (2018), Kirks et al. (2019) y Zhu et al. (2019), manifiestan que los algoritmos propuestos, en cada una de sus investigaciones permiten generar y ejecutar varios escenarios de automatización, que permite proyectarse las industrias en diferentes costos de implementación de estos sistemas automáticos.

Antzoulatos et al. (2014), Griparić et al. (2017) y Passinhas (2017), en un inicio manifiestan proponer sistemas reconfigurables para adaptarse a cambios solicitados por la demanda de los productos, esto hace que se integren diferentes agentes robóticos pero el principal problema es la falta de compatibilidad en los algoritmos manejados al momento de interactuar entre si, buscando un objetivo en común.

Lujak et al. (2021), Kiktev et al. (2021), Stefanova-Stoyanova & Stankov (2020) y Shereuzhev & Serebrenny (2020), dan a conocer cómo evoluciona los algoritmos para los MARS a través del IoT en escenarios definidos, permitiendo simplificar las posibles soluciones, a través de la cooperación de enjambres de robots.

Zhu et al. (2019) en su investigación manifiesta que el rendimiento de los métodos GDM descentralizados se presentaron mediante una aplicación de detección de gas, donde la información sobre la concentración de gas obtenida por una gran red de robots se fusiona y se utiliza para la planificación de rutas basadas en información en un enfoque descentralizado este método permite compartir, almacenar y transferir información personal de forma segura en aplicaciones de robótica y automatización.

Antzoulatos et al. (2014) propone un sistema de producción reconfigurable el cual puede adaptarse automáticamente a los cambios requeridos según las características de los productos, esto involucra varias máquinas trabajando más cerca unos de otros, permitiendo a los agentes diversos incrementar las capacidades de conexión, producción y sobre todo que el sistema se adapte a sí mismo.

Griparić et al. (2017) en su estudio muestra un diseño mecatrónico adecuado a una red estática combinada con actuadores, sensores y unidades, guiados por diferentes tipos de estímulos físicos y descentralizados, los cuales pueden lograr la interacción entre las unidades artificiales y las abejas.

Đurica et al. (2019) indica que mientras exista mayor número de MRSA, el entorno logra un mejor rendimiento con respecto a los tiempos de viaje, las distancias recorridas y el tiempo de ejecución de la orden de transporte, además analiza los principales problemas asociados con las complejidades y etapas de la creación de un sistema robótico multiagente colaborativo industrial.

Deeks (2022) muestra una aplicación en donde combina las necesidades de investigación de los campos del Operador 4.0, Robótica Colaborativa, Inteligencia Artificial Simbólica y Control Automático y mediante la red Q-learning tiene un enfoque viable para intentar producir soluciones sólidas ante un problema de autonomía sincronizada.

Weichhart et al. (2018) en su investigación muestra que los robots colaboran en procesos entre agentes humanos y agentes artificiales en un sistema de producción flexible con este trabajo propone minimizar los conflictos y errores de interacciones que pueden impedir la efectividad de la detección, reduciendo así la calidad de los cultivos.

Shereuzhev & Serebrenny (2020) explica que los robots-agentes muestran que, para una operación segura, es necesario crear arquitecturas de control sociales de CMRS con separación del sistema en el nivel de observación superior, el nivel de descomposición de tareas y el nivel de efectores asociados con los agentes del sistema, robots y humanos. La simulación confirmó plenamente la eficacia de los algoritmos propuestos para la generación y ejecución automatizada de escenarios.

Sekala et al. (2018) revela que el diseño de celdas de trabajo robotizados de un sistema de producción con los sistemas de agentes puede reemplazar a los seres humanos principalmente en muchas funciones de decisión, tomando decisiones más rápidas y precisas, es decir los experimentos numéricos realizados en entornos interiores y exteriores simulados, superan con creces a otros enfoques y evitan colisiones mutuas en tiempo real.

Geersing et al. (2019) manifiesta que la composición robótica de APOTECachemo, cumple con los requisitos microbiológicos de las GMP europeas, realiza soluciones parenterales compuestas individualmente sin riesgo de contaminación.

Stefanova-Stoyanova & Stankov (2020) en su estudio manifiesta que la tecnología DSM con la revolución de MAS

para IoT, propone la creación de soluciones distribuidas finitas, al introducir funcionalidades complejas

Tabla 5 Soluciones de la literatura de los MARS

Nº	Título	Autor	Objetivo del Algoritmo	Problema	Algoritmo de solución	Método de validación	Algoritmos contrastantes	Tamaño del problema resuelto	Tiempo de Cálculo
1	A multi-agent system architecture for self-configuration	Antzoulatos, N. Castro, N. Antzoulatos, E. Castro, D. Scrimieri, and S. Ratchev	Comunicar entre múltiples agentes para satisfacer objetivos individuales	Sistema Multiagente de múltiples capas	Sistema Plug and Produce	Implementación en una celda de producción real de Feintoll Automation	Agente de componentes (CA) Agente de administración Plug and Produce (P&PA) Agente de monitoreo, análisis de datos y optimización (MD)	No se indica	No se indica
2	A robotic system for researching social integration in honeybees	Griparić K, Haus T, Damjan M, Polić M and Bogdan S	Proponer un sistema multi-robot capaz de interactuar con las abejas dentro de una arena experimental	Mecanismos sociales colectivos en una sociedad biohíbrida de robots y abejas	Algoritmo CASU	Experimental	No se indica	50-100 abejas	30 min
3	A route planner using a delegate multi-agent system for a modular manufacturing line: Proof of concept	Durica L, Gregor M, Vavrik V, Marschall M, Grznár P and Mozol S	Aumentar la competitividad de las empresas mediante líneas de fabricación modulares. Minimizar tiempo de viaje y distancia total recorrida	Planificación de rutas en tiempo limitado	Sistema Multiagente MAS	Simulación	Sistema multiagente delegado (D-MAS) MRSA/CA/MRS/MP/MPA/CA/GG	No se indica	No se indica
4	Adapting Multi-agent Swarm Robotics to Achieve Synchronised Behaviour from Production Line Automata	Deeks S	Mejorar tiempo de actividad en las líneas de producción automatizadas	Menor tiempo de aprendizaje	Q Learning	Experimental	No se indica	10 agentes	Escalas 20 min, 90 min y 3h
5	An Agent- and Role-based Planning Approach for Flexible Automation of Advanced Production Systems	Weichhart G, Berglud A, Romero D and Pichler A	Garantizar la adaptabilidad integrada de sistemas heterogéneos de múltiples agentes	Flexibilidad en los procesos automatizados avanzados	No se indica	No se indica	No se indica	No se indica	No se indica
6	Industrial collaborative multi-agent systems: Main challenges	Shereuzhev M and Serebrenny V	Optimizar el rendimiento para resolver problemas	Automatización poco práctica en algunos tipos de tarea de producción	MRS	Simulación	CMRS	No se indica	No se indica
7	Microbiological performance of a robotic system for aseptic compounding of cytostatic drugs	Geersing T, Franssena E, Pilesib F and Crul M	Solucionar parenterales compuestas individualmente sin riesgo de contaminación microbiológica	Procedimientos asepticos estrictos	Robot APOTECA Chemo	Simulación	No se indica	96 preparaciones de llenado	390 min
8	Modelling of a production system using the multi-agent network approach	Sekala A, Gwiazda A, Kost G and Banas W	Mejorar la eficiencia de producción. Modelo de una celda de trabajo robotizada de producción.	Determinar el método para una respuesta flexible y prevenir situaciones que puedan contribuir al retraso de la tarea del robot	MAS	Simulación	No se indica	No se indica	No se indica
9	Multi-Agent systems (MAS) in the area of IoT and using a model with Distributed Shared Memory system (DSM)	Stoyanova V, Stankov I	Intercambiar mensajes sin afectar costos y confiabilidad	Inconsistencia en intercambio de información	MAS	Simulación	IoT, DSM	No se indica	No se indica
10	Robotics and law: A survey	Passinhas S	No se indica	Representación legal de un robot	No se indica	Teórico	No se indica	No se indica	No se indica
11	Scalable Gas Sensing, Mapping, and Path Planning via Decentralized Hilbert Maps	Zhu P, Ferrari S, Morelli J, Linares R and Doerr B	Clasificar clases múltiples	Mapeo de Distribución de Gas	GDM	Simulación	Hilbert Map	No se indica	No se indica
12	Simulation of Multi-Agent Architectures for Fruit and Berry Picking Robot in Active-HDL	Kiktev N; Didyk A; Antonevych M	Planificar automáticamente tareas en tiempo real modelando un grupo de robots.	Definición de algoritmos para procesos automatizados	HDL	Teórico	No se indica	No se indica	No se indica
13	Spillover Algorithm: A decentralised coordination approach for multi-robot production planning in open shared factories	Lujak M, Fernández A and Onaindia E	Minimizar pedidos pendientes totales, inventarios en espera, producción y costos de instalación en tiempo finito dado	Determinar el tamaño de lotes dinámicos	MCLSP-BOSI	Simulación	Algoritmo de desbordamiento, CPLEX	50-150 artículos	No se indica
14	The hub-CI model for telerobotics in greenhouse monitoring	A. S Nair, A. Bechar, Y. Tao and S.Y.Nof	Optimizar la capacidad colaborativa de un sistema robótico agrícola multiagente	Control tele robótico remoto de robots en un entorno agrícola	Modelo HUC-BI	Simulación	Componente red del ARS	No se indica	No se indica
15	The Use of Blockchain Technology for Private Data Handling for Mobile Agents in Human-Technology Interaction	Kirks T, Uhlott T, and Jost J	Garantizar la adaptabilidad integrada de sistemas heterogéneos de múltiples agentes	Integración de humanos en sistemas técnicos	CTV	Simulación	AGV	No se indica	No se indica

de los grandes sistemas reduciendo el tiempo de desarrollo, muestra su primer algoritmo descentralizado para la solución del problema estudiado en entornos intrínsecamente descentralizados donde los recursos de producción y/o los productos son propiedad de múltiples partes interesadas con objetivos posiblemente conflictivos.

Passinhas (2017) explica que la representación legal de un robot depende de una persona jurídica una persona con derechos y deberes propios. Un agente estricto en el campo del derecho comercial y finalmente una fuente de responsabilidad para otros agentes del sistema. La valoración del nivel conciencia, libre albedrío e intencionalidad.

Kiktev et al. (2021) exteriorizan que los MARS, se presentan en forma de típicas máquinas de estado, para la simulación de estados de robots en escenarios definidos implícitamente que permiten la planificación y el seguimiento de las tareas en tiempo real, en definitiva, la cooperación de los enjambres de robots y su potencial para futuras aplicaciones es exitosa.

Nair et al. (2019) indican que las simulaciones de las interacciones colaborativas planificadas y optimizadas con HUB-CI con programas como Python producen menos errores y una mejora detección al mejorar el sistema.

Lujak et al. (2021) dan a conocer su modelo descentralizado y dinámico variante del clásico problema a MCLSP-BOSI con costos dependientes del tiempo este algoritmo de desbordamiento se basó en subastas que aprovecha al efecto indirecto, este modelo y la tecnología DSM es necesaria en el campo para la rápida evolución de MAS para IoT, lo que permite simplificar significativamente la creación de soluciones distribuidas finitas, al introducir funcionalidades complejas de los "grandes sistemas", reduciendo el tiempo de desarrollo.

Kirks et al. (2019) indica una arquitectura a través de un método seguro para un sistema de control descentralizado adaptativo para la interacción de tecnología humana con sistemas multi robot como flotas de AGV. El agente de software humano móvil fue diseñado para garantizar la adaptabilidad integrada de sistemas heterogéneos múltiples agentes.

6.3. Futuras líneas de investigación

Las principales líneas de investigación serán los modelos experimentales y de simulación dentro de la programación y control de operaciones productivas y logísticas basados en la filosofía de colaboración humano – robot, puesto que la interacción entre los enjambres de robots debe proponer soluciones que tengan capacidad de razonamiento humano, con una memoria a largo plazo para que según su rol cada agente cumpla actividades específicas interactuando con

el medio, así lo indican Stefanova-Stoyanova & Stankov (2020), Kirks et al. (2020), Kiktev et al. (2021) y Weichhart et al. (2018).

La segunda línea de aplicación indica que el desarrollo de algoritmos de aprendizaje automáticas y los escenarios simulados, deben ser trasladados a entornos reales, sin embargo el principal limitante es la inversión Antzoulatos et al. (2014) y Kiktev et al. (2021).

7. Conclusiones

La aplicación de algoritmos de aprendizaje en los MARS para la programación y control de operaciones productivas y logísticas, son soluciones muy importantes, debido que, en las simulaciones, se puede realizar pruebas donde intervienen diferentes agentes inteligentes en varios ambientes de trabajo que cooperan entre sí para alcanzar un objetivo común.

Los métodos de validación de las investigaciones analizadas han sido en su mayoría las simulaciones con un 60% del total, posteriormente están las metodologías experimentales con 13%, la metodología teórica con un 13%, de igual manera se encuentran la Celda de producción – Feitoll Automation con 7%, finalmente con el 7% un trabajo no especifica la metodología de validación.

Existen varios algoritmos de aprendizaje, entre los más sobresalientes con modelos MAS, Q learning, y otros específicos de cada estudio como el del Robot APOTECachemo. Además, los estudios presentan en su mayoría la intervención de 10 agentes, sin embargo, en la utilización del algoritmo CASU intervienen de 50 – 100 abejas. Los resultados más relevantes buscan permitir una mayor concurrencia de agentes inteligentes diferentes que interactúen entre sí.

La principal limitante de los algoritmos de aprendizaje utilizado en los MARS es que no se han podido trasladar de simulaciones a entornos reales, debido a la falta de capacidad de razonamiento humano de los robots.

Referencias

- Antzoulatos, N., Castro, E., Scrimieri, D., & Ratchev, S. (2014). A multi-agent system architecture for self-configuration. In IFIP Advances in Information and Communication Technology (Vol. 435, pp. 118–125). https://doi.org/10.1007/978-3-662-45586-9_15
- Arques Corrales, P., & Aznar Gregori, F. (2020). Swarm AGV Optimization Using Deep Reinforcement Learning. PervasiveHealth: Pervasive Computing Technologies for Healthcare, 65–69. <https://doi.org/10.1145/3426826.3426839>

- Boldrer, M., Antonucci, A., Bevilacqua, P., Palopoli, L., & Fontanelli, D. (2022). Multi-agent navigation in human-shared environments: A safe and socially-aware approach. *Robotics and Autonomous Systems*, 149, 103979. <https://doi.org/10.1016/J.ROBOT.2021.103979>
- Deeks, C. (2022). Adapting Multi-agent Swarm Robotics to Achieve Synchronised Behaviour from Production Line Automata. In H. W. & S. J.M. (Eds.), 2nd IMA Conference on Mathematics of Robotics, IMA 2020: Vol. 21 SPAR (pp. 13–24). Springer Nature. https://doi.org/10.1007/978-3-030-91352-6_2
- Demesure, G., Defoort, M., Bekrar, A., Trentesaux, D., & Djemai, M. (2014). Cooperation mechanisms in multi-agent robotic systems and their use in distributed manufacturing control: Issues and literature review. *IECON Proceedings (Industrial Electronics Conference)*, 2538–2543. <https://doi.org/10.1109/IECON.2014.7048863>
- Đurica, L., Gregor, M., Vavřík, V., Marschall, M., Grznár, P., & Mozol, Š. (2019). A route planner using a delegate multi-agent system for a modular manufacturing line: Proof of concept. *Applied Sciences (Switzerland)*, 9(21). <https://doi.org/10.3390/app9214515>
- Geersing, T. H., Franssen, E. J. F., Pilesi, F., & Crul, M. (2019). Microbiological performance of a robotic system for aseptic compounding of cytostatic drugs. *European Journal of Pharmaceutical Sciences*, 130, 181–185. <https://doi.org/10.1016/j.ejps.2019.01.034>
- Griparić, K., Haus, T., Miklič, D., Polić, M., & Bogdan, S. (2017). A robotic system for researching social integration in honeybees. *PLoS ONE*, 12(8). <https://doi.org/10.1371/journal.pone.0181977>
- Guzmán, E., Poler, R., & Andrés, B. (2020). Un análisis de revisiones de modelos y algoritmos para la optimización de planes de aprovisionamiento, producción y distribución de la cadena de suministro. *Dirección y Organización*, 70, 28–52. <https://doi.org/10.37610/DYO.V0I70.567>
- Kiktev, N., Didyk, A., & Antonevych, M. (2021). Simulation of Multi-Agent Architectures for Fruit and Berry Picking Robot in Active-HDL. 2020 IEEE International Conference on Problems of Infocommunications Science and Technology, PIC S and T 2020 - Proceedings, 635–640. <https://doi.org/10.1109/PICST51311.2020.9467936>
- Kirks, T., Jost, J., Finke, J., & Hoose, S. (2020). Modelling proxemics for human-technology-interaction in decentralized social-robot-systems. In *Advances in Intelligent Systems and Computing: Vol. 1131 AISC* (pp. 153–158). https://doi.org/10.1007/978-3-030-39512-4_24
- Kirks, T., Uhloft, T., & Jost, J. (2019). The Use of Blockchain Technology for Private Data Handling for Mobile Agents in Human-Technology Interaction. *Proceedings of the IEEE 2019 9th International Conference on Cybernetics and Intelligent Systems and Robotics, Automation and Mechatronics, CIS and RAM 2019*, 445–450. <https://doi.org/10.1109/CIS-RAM47153.2019.9095771>
- Li, P., Wu, X., Chsen, X., & Qiu, J. (2022). Distributed adaptive finite-time tracking for multi-agent systems and its application. *Neurocomputing*, 481, 46–54. <https://doi.org/10.1016/J.NEUCOM.2022.01.065>
- Lujak, M., Fernández, A., & Onaindia, E. (2021). Spillover Algorithm: A decentralised coordination approach for multi-robot production planning in open shared factories. *Robotics and Computer-Integrated Manufacturing*, 70. <https://doi.org/10.1016/j.rcim.2020.102110>
- Nair, A. S., Bechar, A., Tao, Y., & Nof, S. Y. (2019). The hub-CI model for telerobotics in greenhouse monitoring. *Procedia Manufacturing*, 39, 414–421. <https://doi.org/10.1016/j.promfg.2020.01.385>
- Nilles, A., Wasserman, J., Born, A., Horn, C., Born, J., & Laval, S. M. (2019). A Hardware and Software Testbed for Underactuated Self-Assembling Robots: Extended Abstract. 2nd International Symposium on Multi-Robot and Multi-Agent Systems, MRS 2019, 7–9. <https://doi.org/10.1109/MRS.2019.8901081>
- Papadopoulos, G. T., Antona, M., & Stephanidis, C. (2021). Towards Open and Expandable Cognitive AI Architectures for Large-Scale Multi-Agent Human-Robot Collaborative Learning. *IEEE Access*, 9, 73890–73909. <https://doi.org/10.1109/ACCESS.2021.3080517>
- Passinhas, S. (2017). Robotics and law: A survey. *CEUR Workshop Proceedings*, 2059, 54–60. <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85042457485&partnerID=40&md5=087f2a71b18b69c9c3a07a80f00bbcf>
- Pérez-Cubero, E., & Poler, R. (2021). Aplicación de algoritmos de aprendizaje automático a la programación de órdenes de producción en talleres de trabajo: Una revisión de la literatura reciente. *Dirección y Organización*, 72, 82–94. <https://doi.org/10.37610/DYO.V0I72.588>

- Ross, K., & Ross, K. (2022). Artificial Intelligence in Fashion Manufacturing: From Factory Operation to Advisory Role. *Leading Edge Technologies in Fashion Innovation*, 95–116.
https://doi.org/10.1007/978-3-030-91135-5_6
- Sagar, K., Lugo, J. H., Molfino, R., Zlatanov, D., Zoppi, M., & Muthuswamy, S. (2018). Coordinated Selection and Timing of Multiple Trajectories of Discretely Mobile Robots. In Z. M. & M. S. (Eds.), *1st International Conference on Robotics and Smart Manufacturing, RoSMa 2018* (Vol. 133, pp. 676–683). Elsevier B.V.
<https://doi.org/10.1016/j.procs.2018.07.103>
- Sekala, A., Gwiazda, A., Kost, G., & Banas, W. (2018). Modelling of a production system using the multi-agent network approach. *IOP Conference Series: Materials Science and Engineering*, 400(5).
<https://doi.org/10.1088/1757-899X/400/5/052009>
- Serebrenny, V., Lapin, D., Mokaeva, A., & Shereuzhev, M. (2019). Technological collaborative robotic systems. In M. E.A., R. D.O., A. A.A., S. V.A., F. I.B., & M. V.I. (Eds.), *43rd Academic Space Conference: Dedicated to the Memory of Academician S.P. Korolev and Other Outstanding Russian Scientists - Pioneers of Space Exploration “Korolev Academic Space Conference”* (Vol.2171). American Institute of Physics Inc.
<https://doi.org/10.1063/1.5133319>
- Shereuzhev, M., & Serebrenny, V. (2020). Industrial collaborative multi-agent systems: Main challenges. In *Smart Innovation, Systems and Technologies* (Vol. 154, pp. 423–429).
https://doi.org/10.1007/978-981-13-9267-2_34
- Stefanova-Stoyanova, V., & Stankov, I. (2020). Multi-Agent systems (MAS) in the area of IoT and using a model with Distributed Shared Memory system (DSM). *2020 29th International Scientific Conference Electronics, ET 2020 - Proceedings*.
<https://doi.org/10.1109/ET50336.2020.9238153>
- Webster, M., Dixon, C., Fisher, M., Salem, M., Saunders, J., Koay, K. L., & Dautenhahn, K. (2014). Formal verification of an autonomous personal robotic assistant. *2014 AAAI Spring Symposium, SS-14-02*, 74–79.
<https://www.scopus.com/inward/record.uri?eid=2-s2.0-84904858162&partnerID=40&md5=92c3f101febdcc71b7d081fb33a35df3>
- Weichhart, G., Fast-Berglund, A., Romero, D., & Pichler, A. (2018). An Agent- and Role-based Planning Approach for Flexible Automation of Advanced Production Systems. *9th International Conference on Intelligent Systems 2018: Theory, Research and Innovation in Applications, IS 2018 - Proceedings*, 391–399.
<https://doi.org/10.1109/IS.2018.8710546>
- Wen, L., Liu, Y., & Li, H. (2022). CL-MAPF: Multi-Agent Path Finding for Car-Like robots with kinematic and spatiotemporal constraints. *Robotics and Autonomous Systems*, 150, 103997.
<https://doi.org/10.1016/J.ROBOT.2021.103997>
- Zafeiropoulos, A., Fotopoulou, E., Filinis, N., & Papavassiliou, S. (2022). Reinforcement learning-assisted autoscaling mechanisms for serverless computing platforms. *Simulation Modelling Practice and Theory*, 116, 102461.
<https://doi.org/10.1016/J.SIMPAT.2021.102461>
- Zhu, P., Ferrari, S., Morelli, J., Linares, R., & Doerr, B. (2019). Scalable gas sensing, mapping, and path planning via decentralized hilbert maps. *Sensors (Switzerland)*, 19(7). <https://doi.org/10.3390/s19071524>
- Zinn, J., Vogel-Heuser, B., & Gruber, M. (2021). Fault-Tolerant control of programmable logic controller-based production systems with deep reinforcement learning. *Journal of Mechanical Design, Transactions of the ASME*, 143(7). <https://doi.org/10.1115/1.4050624>